



Universidade Federal de Campina Grande
Programa de Pós-graduação em Engenharia Elétrica - PPgEE

Mestrado em Engenharia Elétrica
Linha de pesquisa: MXAI

Ficha de Leitura

*Multimodal Explainable Artificial Intelligence: A Comprehensive
Review of Methodological Advances and Future Research
Directions*

Mestrando: Alysson Machado de Oliveira Barbosa
Orientador: Prof. Dr. Wamberto José Lira de Queiroz
Coorientadora: Profa. Dra. Luciana Ribeiro Veloso

Campina Grande – PB
2026

Ideia Central

O artigo é uma revisão sistemática sobre *Multimodal Explainable Artificial Intelligence* (MXAI), isto é, explicabilidade aplicada a sistemas nos quais múltiplas modalidades aparecem na tarefa preditiva, na explicação ou na relação entre entrada e explicação.

Palavras-chave: *Artificial intelligence; deep learning; evaluation; explanation; multimodal explainable artificial intelligence; neural networks.*

Sumário

1	Introdução	2
2	Predição multimodal e explicabilidade	2
2.1	Modalidades, representações e fusão	2
2.2	Explicação multimodal	2
2.3	Tarefas e dados para explicabilidade	3
3	Classificação dos métodos	4
3.1	Crítérios de XAI unimodal	4
3.2	Combinações de tarefa e explicação	5
3.3	Explicabilidade em UU e UM	6
3.4	Explicabilidade em MU e MM	6
4	Estágios da explicabilidade	7
4.1	Explicações intrínsecas	7
4.2	Análise posterior da predição	9
4.3	Módulo de explicação separado	10
5	Mecanismos de explicabilidade	10
5.1	Atribuição de relevância a regiões, palavras e sinais	10
5.2	Contribuições individuais e interações entre modalidades	11
5.3	Atributos, conceitos e grafos	12
5.4	Raciocínio, contrafactuais, interação e fusão	12
6	Métricas de Explicabilidade	12
6.1	O que está sendo medido	12
6.2	Métricas no domínio textual	13
6.3	Métricas no domínio visual	13
6.4	Avaliação das relações entre modalidades	14
7	Desafios e limites discutidos no artigo	14
7.1	Atenção, fidelidade e causalidade	14
7.2	Dados, generalização e definições	15
	Referências	15

1 Introdução

Um modelo pode acertar uma resposta sem utilizar a informação que se esperava que ele utilizasse. Em uma tarefa que combina imagem e pergunta, por exemplo, a resposta pode ser inferida a partir de padrões frequentes nas perguntas, com pouca participação da imagem. Avaliar apenas a taxa de acerto não revela essa diferença. A explicabilidade procura examinar quais informações sustentam a predição e como o comportamento do modelo pode ser compreendido.

Rodis et al. (2024) estudam esse problema no contexto da inteligência artificial explicável multimodal, ou MXAI, do inglês *Multimodal Explainable Artificial Intelligence*. O artigo é uma revisão da literatura, na qual sua contribuição está na organização de tarefas, bases de dados, métodos e critérios de avaliação. Os autores não propõem modelos novos nem apresentam experimentos comparativos.

A revisão foi publicada em 2024. A busca descrita pelos autores abrange IEEE Xplore, Google Scholar, Scopus, DBLP, arXiv e Web of Science. O processo inclui refinamento dos termos de busca, consulta às referências dos trabalhos encontrados, remoção de duplicatas, seleção por título e resumo e leitura dos textos completos. Foram excluídos artigos que não estavam em inglês, trabalhos sem acesso ao texto completo e estudos fora do escopo definido para MXAI. Os autores informam a seleção de 94 artigos para análise (Rodis et al. 2024, seção II).

O texto declara prioridade para os cinco anos anteriores à revisão, com inclusão de trabalhos anteriores considerados relevantes. O exemplo de consulta à Scopus usa anos maiores que 2020 e menores que 2025. Esses detalhes delimitam a cobertura da revisão.

2 Predição multimodal e explicabilidade

2.1 Modalidades, representações e fusão

Uma modalidade é uma forma de representar ou observar informação, como imagem, texto, áudio, dados tabulares ou grafos. Um problema multimodal envolve mais de uma dessas formas. Em análise de sentimentos, por exemplo, o conteúdo verbal, a entonação e a expressão facial podem fornecer informações diferentes sobre uma mesma manifestação.

Para fixar a notação, considere um modelo que recebe M modalidades. Uma descrição didática de seu funcionamento é

$$z_m = h_m(x^{(m)}), \quad \hat{y} = g(z_1, \dots, z_M), \quad (1)$$

em que $x^{(m)}$ é a entrada da modalidade m , h_m é a função que a transforma em uma representação z_m e g combina as representações para produzir a predição $\hat{y}$. Uma representação pode ser um vetor numérico aprendido por uma rede neural, frequentemente chamado de *embedding*. A expressão não exige que todas as arquiteturas tenham módulos separados exatamente dessa forma, a ideia é distinguir a informação de cada modalidade e sua combinação.

A *fusão* é o mecanismo que combina essas informações. Ela pode envolver concatenação, operações entre vetores, atenção ou outras funções aprendidas. Explicar a fusão exige observar tanto a contribuição individual de uma modalidade quanto aquilo que muda quando ela é combinada com outra. A frase “está ótimo”, acompanhada de uma entonação de desagrado, é um exemplo hipotético, na qual o sentido sugerido pelo conjunto pode diferir do sentido atribuído ao texto isolado.

2.2 Explicação multimodal

No uso adotado pelo artigo, MXAI não se limita a modelos com entradas multimodais. Também estão incluídos sistemas que produzem explicações em mais de uma modalidade e sistemas em que a entrada e a explicação são unimodais, mas pertencem a modalidades diferentes. Um classificador que recebe apenas uma imagem e explica sua decisão por uma frase já se enquadra nesse último caso (Rodis et al. 2024, seção I).

É necessário distinguir três componentes: a entrada da tarefa, a resposta predita e a explicação dessa resposta. Na classificação de uma ave, a imagem é a entrada, o nome da espécie é a predição e a descrição dos atributos usados para justificá-la é a explicação. Uma descrição genérica, como “há uma ave no galho”, pode ser uma legenda adequada da cena, mas não informa o que diferencia a espécie escolhida das alternativas.

A Figura 1 mostra formas distintas de apresentar evidências. No painel (a), mapas de relevância são sobrepostos às imagens para inspecionar regiões associadas à classificação. No painel (b), os mapas aparecem acompanhados de frases que mencionam atributos das aves. A combinação permite relacionar uma afirmação textual à região visual correspondente.




Figura 1: Explicações visuais e explicações que combinam evidências visuais e textuais. (Rodis et al. 2024, Fig. 1).

Essa relação precisa ser avaliada. Uma frase pode descrever corretamente a imagem sem refletir a informação usada pelo classificador. Da mesma forma, um mapa pode destacar o objeto esperado pelo leitor, embora o modelo também dependa de características do fundo. Os autores trazem uma discussão acerca dessa relação, na qual convém perguntar separadamente se a explicação é compreensível, se corresponde à entrada e se acompanha o comportamento do modelo.

2.3 Tarefas e dados para explicabilidade

O artigo reúne aplicações que incluem perguntas sobre imagens, geração de legendas, classificação visual, reconhecimento de ações, análise de sentimentos, recomendação, direção automatizada e diagnóstico assistido por computador. Cada tarefa estabelece uma relação diferente entre aquilo que o sistema prevê e aquilo que precisa explicar (Rodis et al. 2024, seção III).

Em *Visual Question Answering* (VQA), o sistema recebe uma imagem e uma pergunta e produz uma resposta. Diante de “em que o homem está sentado?”, identificar uma cadeira na imagem e relacioná-la à pessoa são operações relevantes. Uma explicação pode indicar a região da cadeira, as palavras que orientaram a busca e a relação espacial que sustenta a resposta. Por combinar diretamente visão e linguagem, VQA aparece com frequência na revisão.

Na geração de legendas, a tarefa consiste em produzir uma sequência textual para descrever uma imagem ou um vídeo. A explicação pode ser associada a cada palavra, indicando em que região contribuiu para gerar “ave”, ou que intervalo do vídeo contribuiu para gerar um verbo de ação. Nos modelos sequenciais discutidos no artigo, as palavras já produzidas também podem participar da predição das palavras seguintes.

Na classificação de categorias visualmente semelhantes, a explicação costuma recorrer a atributos, como cor, formato do bico ou padrão da plumagem. Em *zero-shot learning*, o modelo busca reconhecer classes sem exemplos de treinamento dessas classes na tarefa considerada, utilizando descrições ou relações semânticas. Os atributos ajudam a conectar a representação visual às descrições das categorias.

Treinar a tarefa preditiva e avaliar sua explicação requerem anotações diferentes. Uma base

com imagens e respostas corretas permite medir acerto na tarefa, mas não fornece, por si só, uma referência de explicação. As Tabelas 1 e 2 do artigo distinguem conjuntos de dados que oferecem recursos adicionais, como justificativas textuais, regiões anotadas, atributos ou relações entre objetos. Alguns exemplos são:

- **VQA-X e VQA-E:** acrescentam justificativas à tarefa de responder perguntas sobre imagens. VQA-X também inclui explicações visuais coletadas de pessoas.
- **TextVQA-X:** contém explicações visuais e textuais para uma tarefa de perguntas que envolve leitura de texto nas imagens.
- **VQA-HAT:** disponibiliza mapas de atenção humana, usados para comparar as regiões observadas por pessoas com as regiões destacadas pelo modelo.
- **CLEVR:** utiliza cenas sintéticas e programas simbólicos, permitindo examinar etapas de raciocínio, como selecionar, relacionar e contar objetos.
- **Visual Genome e Flickr30k Entities:** fornecem relações ou correspondências entre elementos visuais e descrições textuais que podem apoiar a avaliação do alinhamento entre modalidades.
- **ACT-X e BDD-X:** oferecem explicações relacionadas, respectivamente, a atividades e ações em vídeos de direção.

3 Classificação dos métodos

3.1 Critérios de XAI unimodal

A Figura 2 organiza os critérios usados na revisão. O lado esquerdo reúne dimensões que também podem ser aplicadas a explicações unimodais; o lado direito apresenta os três eixos enfatizados para MXAI. Os eixos são complementares, na qual um mesmo método pode receber uma classificação em cada um deles (Rodis et al. 2024, seção IV-A).




Figura 2: Critérios de classificação das abordagens de XAI e MXAI (Rodis et al. 2024, Fig. 3).

Quanto ao objetivo, uma explicação pode buscar *introspecção*, isto é, examinar o funcionamento do modelo, ou apresentar uma *justificativa* para a predição em uma forma compreensível ao usuário. Essa distinção ajuda a evitar que uma descrição plausível seja tomada automaticamente como uma descrição do cálculo realizado pelo modelo.

Quanto ao alcance, uma explicação *local* se refere a uma entrada ou predição específica. Uma explicação *global* procura descrever regularidades do comportamento do modelo em um conjunto de situações. Dizer que o áudio foi relevante para uma frase particular é uma afirmação local, dizer que o modelo costuma depender do áudio em determinado tipo de situação exige análise de vários exemplos.

Quanto à dependência da arquitetura, métodos *agnósticos ao modelo* usam uma interface que pode ser aplicada a diferentes preditores, como consultar suas respostas a entradas modificadas. Métodos *específicos ao modelo* dependem de componentes internos, como gradientes, mapas de ativação ou parâmetros de atenção.

3.2 Combinações de tarefa e explicação

As letras U e M indicam, respectivamente, unimodal e multimodal. A primeira letra caracteriza as modalidades da tarefa preditiva, a segunda caracteriza as modalidades da explicação. A resposta da tarefa não deve ser confundida com sua explicação. A Figura 3 apresenta exemplos das quatro combinações.




Figura 3: Combinações UU, UM, MU e MM entre tarefa preditiva e explicação (Rodis et al. 2024, Fig. 4).

- **UU: tarefa unimodal e explicação unimodal.** Para pertencer ao escopo de MXAI usado na revisão, a modalidade da explicação deve ser diferente da modalidade de entrada. O exemplo do painel (a) recebe uma imagem de ave e produz uma justificativa textual.
- **UM: tarefa unimodal e explicação multimodal.** A entrada continua sendo uma imagem, mas a explicação combina, por exemplo, um mapa de relevância e uma frase sobre atributos. No painel (b), a frase permite nomear características da ave, enquanto o mapa procura localizá-las.

- **MU: tarefa multimodal e explicação unimodal.** O painel (c) reúne imagem e pergunta na entrada, mas explica a resposta por um mapa visual.
- **MM: tarefa multimodal e explicação multimodal.** No painel (d), imagem e pergunta originam uma resposta, um mapa visual e uma justificativa textual. É possível inspecionar o que foi destacado na imagem e como essa evidência foi articulada em palavras.

3.3 Explicabilidade em UU e UM

Nas abordagens UU, a revisão reúne justificativas textuais e explicações por grafos. As primeiras podem mencionar atributos que distinguem a classe prevista. Nos grafos, os nós representam entidades ou conceitos, e as arestas representam relações entre eles. A Figura 4 mostra que uma explicação também pode descrever relações e mudanças de estado, em vez de apenas destacar pixels (Rodis et al. 2024, seção IV-C1).




Figura 4: Exemplos UU: justificativas textuais, relações entre objetos e representação de estados em uma sequência visual (Rodis et al. 2024, Fig. 6).

Considere, como exemplo didático, a diferença entre detectar uma pessoa, uma xícara e uma mesa e representar a relação “a pessoa segura a xícara”. Os objetos isolados não descrevem a ação. A relação acrescenta informação sobre como eles participam da cena. Em vídeo, acompanhar uma mudança, como uma porta que passa de fechada a aberta, pode ajudar a explicar a atividade reconhecida.

Nas abordagens UM, a explicação associa representações diferentes. A revisão descreve combinações de mapas com texto, exemplos visuais com atributos e grafos com respostas textuais. Na Figura 5, o painel (a) relaciona atributos a regiões da ave, o painel (b) associa uma justificativa a detalhes visuais, o painel (c) apresenta imagens recuperadas para comparação e o painel (d) combina relações em um grafo com interação textual (Rodis et al. 2024, seção IV-C2).

3.4 Explicabilidade em MU e MM

Na categoria MU, uma explicação visual, textual ou baseada em *scores* pode sintetizar o processamento de várias entradas. A Figura 6 reúne mapas associados à geração de palavras, explicações textuais apoiadas em grafos, comparação entre exemplos e análise de contribuições na







Figura 5: Exemplos UM com atributos, regiões visuais, imagens de comparação e relações acompanhadas de texto (Rodis et al. 2024, Fig. 7).

identificação de sentimentos. Ela evidencia que o formato da explicação não precisa repetir todos os formatos da entrada (Rodis et al. 2024, seção IV-C3).



Na categoria MM, a revisão apresenta mapas sobre imagem e texto, mapas visuais acompanhados de frases, atributos textuais associados a regiões e outras combinações. Na Figura 7(a), a explicação distribui relevância entre regiões da imagem e partes da pergunta. No painel (b), respostas iguais podem ser acompanhadas de justificativas diferentes, na qual comparar essas justificativas com as imagens permite examinar se a evidência apresentada sustenta a resposta (Rodis et al. 2024, seção IV-C4).

4 Estágios da explicabilidade

4.1 Explicações intrínsecas

O segundo eixo considera a relação entre a explicação e o desenvolvimento ou uso do preditor. Na categoria intrínseca da revisão, a explicação explora componentes internos do próprio modelo, como atenção e parâmetros de fusão. A Figura 8 ilustra atenção em etapas, alinhamento com regiões de interesse e contribuições de modalidades (Rodis et al. 2024, seção IV-D1).

Um mecanismo de atenção calcula os pesos do modelo para combinar representações. Em VQA, esses pesos podem variar com a pergunta, como por exemplo perguntar pela cor de um objeto pode direcionar o processamento para regiões diferentes daquelas usadas para contar pessoas. Visualizar os pesos permite observar parte desse processamento.






Figura 8: Explicações classificadas como intrínsecas, considerando mecanismos de atenção, regiões de interesse e importância de modalidades (Rodis et al. 2024, Fig. 10).

4.2 Análise posterior da predição

Métodos *post-hoc* examinam um preditor já construído. Uma possibilidade é modificar a entrada e observar a alteração da saída. Outra é analisar informações internas disponíveis, como gradientes, sem refazer o treinamento. Na Figura 9, aparecem exemplos associados a legendas de vídeo, classificação visual, VQA e sinais biomédicos (Rodis et al. 2024, seção IV-D2).




Figura 9: Exemplos de análise posterior à construção do preditor em diferentes tarefas. (Rodis et al. 2024, Fig. 11).

Há uma ressalva de terminologia na leitura, a definição inicial do artigo associa *post-hoc* à análise de saídas e ao tratamento do preditor como caixa-preta, mas a discussão posterior inclui métodos baseados em retropropagação. Portanto, o estágio de geração e o acesso à arquitetura devem ser registrados separadamente. Ser aplicado depois do treinamento não torna um método automaticamente agnóstico ao modelo.

Em um dos exemplos descritos na revisão, uma modalidade de sinais é substituída por ruído, e a mudança nas probabilidades de saída é observada. A pergunta respondida por esse procedimento

é como o preditor reage àquela intervenção. O resultado depende também do tipo de ruído e de quão diferente a entrada modificada fica das entradas usadas no treinamento.

4.3 Módulo de explicação separado

Uma terceira opção consiste em construir um módulo específico para gerar explicações. Ele pode receber representações internas, a predição, atributos ou evidências da entrada. A distinção seguinte diz respeito ao treinamento, na qual o explicador pode ser aprendido junto com o preditor ou depois dele (Rodis et al. 2024, seção IV-D3).

No *treinamento conjunto*, os objetivos de predição e explicação participam do aprendizado. Uma representação dessa combinação pode ser dada por

$$\mathcal{L} = \mathcal{L}_{\text{pred}} + \lambda \mathcal{L}_{\text{exp}}, \quad \lambda \geq 0, \quad (2)$$

em que $\mathcal{L}_{\text{pred}}$ mede o erro na tarefa principal, $\mathcal{L}_{\text{exp}}$ mede o erro segundo o objetivo escolhido para a explicação e λ controla sua participação. A equação resume uma possibilidade de treinamento, sem reproduzir a função de perda de todos os métodos revisados.

No *treinamento incremental*, no sentido usado pelo artigo, o preditor é desenvolvido primeiro e o módulo explicador é construído posteriormente. Isso pode permitir o uso de um modelo já disponível.




Figura 10: Módulos separados de explicação com treinamento conjunto ou incremental (Rodis et al. 2024, Fig. 12).

A Figura 10 apresenta módulos separados de explicação em diferentes tarefas e regimes de treinamento. No painel (a), o treinamento conjunto permite produzir uma resposta à pergunta sobre a imagem e uma justificativa textual. O painel (b) apresenta uma abordagem de reconhecimento de classes não vistas no treinamento, com explicações visuais e textuais, estudada com treinamento incremental e conjunto. No painel (c), um módulo treinado posteriormente ao preditor associa a justificativa da resposta a regiões da imagem. O painel (d) apresenta um módulo de explicação treinado após o classificador de vídeos. Esse módulo avalia combinações de atributos textuais e regiões espaço-temporais para explicar por que uma classe é favorecida em relação a outra.

5 Mecanismos de explicabilidade

5.1 Atribuição de relevância a regiões, palavras e sinais

Atribuir relevância consiste em associar valores a partes da entrada ou de uma representação para caracterizar sua participação na predição. Em uma imagem, o resultado pode ser um mapa

de calor; em texto, uma marcação sobre palavras; em sinais, *scores* por canal ou intervalo. O significado desses valores depende do método empregado.

A revisão descreve extensões de métodos originalmente estudados em XAI unimodal. A Figura 11 reúne quatro exemplos de aplicação em tarefas que relacionam visão e linguagem (Rodis et al. 2024, seção IV-B).




Figura 11: Aplicações de Grad-CAM++, LIFT-CAM, RISE e retropropagação guiada em cenários multimodais (Rodis et al. 2024, Fig. 5).

- **Grad-CAM e Grad-CAM++.** Grad-CAM utiliza gradientes de uma saída de interesse em relação a mapas de ativação de uma camada convolucional para produzir uma localização de regiões relevantes. Grad-CAM++ modifica a ponderação e é apresentado na revisão como uma alternativa para localizar múltiplas ocorrências de objetos.
- **LIFT-CAM e combinação de SHAP com Grad-CAM.** LIFT-CAM utiliza uma aproximação de contribuições de Shapley por DeepLIFT na construção de mapas. Em outro exemplo da revisão, SHAP é aplicado a dados tabulares e Grad-CAM à imagem.
- **Gradientes integrados, LRP e retropropagação guiada.** Gradientes integrados acumulam informação de gradientes ao longo de um caminho entre uma referência e a entrada examinada. A escolha dessa referência participa da interpretação da atribuição. LRP redistribui relevância da saída pelas camadas da rede. A retropropagação guiada usa uma regra modificada de propagação de gradientes para visualizar características da entrada.
- **RISE.** Esse método aplica máscaras à imagem e consulta a saída do modelo. A agregação das máscaras, ponderadas pelas respostas observadas, produz um mapa de relevância.

5.2 Contribuições individuais e interações entre modalidades

O método DIME, descrito pela revisão, estende a ideia de explicações locais do LIME para distinguir contribuições unimodais e interações multimodais. LIME aproxima o comportamento de um preditor nas proximidades de uma entrada por um modelo interpretável. DIME aplica essa lógica às parcelas separadas pela decomposição (Rodis et al. 2024, seção IV-B1).

Como representação, considere uma pontuação de saída s para duas modalidades:

$$s(x^{(1)}, x^{(2)}) \approx b + u_1(x^{(1)}) + u_2(x^{(2)}) + v(x^{(1)}, x^{(2)}). \quad (3)$$

Aqui, b representa uma referência, u_1 e u_2 representam parcelas individuais e v representa uma parcela associada à combinação. Separar essas parcelas requer especificar a referência, as perturbações e a vizinhança usadas na análise.

Volte ao exemplo de uma frase acompanhada de entonação de desagrado. Um *score* alto para uma palavra e outro para um trecho de áudio não informam, isoladamente, se o modelo interpretou a discordância entre eles. Para investigar essa relação, pode-se comparar a resposta à frase com diferentes entonações, mantendo o restante da entrada controlado.

A técnica de ablação (*feature ablation*) trata de remover ou substituir uma modalidade e observar o efeito dessa ação. Um efeito pequeno não significa necessariamente que ela seja inútil. Outra modalidade pode fornecer informação redundante, ou a alteração pode ter preservado justamente as características usadas pelo modelo.

5.3 Atributos, conceitos e grafos

Atributos aproximam a explicação de propriedades que podem ser nomeadas, como formato, cor ou presença de uma parte. Em vez de apresentar somente uma região destacada, o método pode associá-la ao atributo, por exemplo, “ave amarela”. O leitor passa a poder examinar tanto a localização quanto a propriedade atribuída a ela (Rodis et al. 2024, seção IV-E).

Conceitos permitem formular perguntas sobre representações mais amplas. A revisão descreve o uso de vetores de ativação de conceitos, ou CAV, para relacionar direções no espaço de representações a conceitos definidos a partir de exemplos. A análise procura medir como esses conceitos se relacionam à saída examinada. O resultado depende da definição do conceito e dos exemplos usados para representá-lo.

Grafos representam entidades e relações. Em uma pergunta como “o que está sobre a mesa?”, identificar a mesa e os objetos não se mostra suficiente, é importante destacar a relação espacial entre os elementos. Uma explicação baseada em grafo pode explicitar esse encadeamento.

5.4 Raciocínio, contrafactuais, interação e fusão

Sob o termo *reasoning*, a revisão reúne abordagens que produzem justificativas e respostas, inclusive por aprendizado com múltiplos objetivos. Uma sequência textual de passos pode facilitar a leitura, mas sua forma sequencial não demonstra que cada passo tenha sido executado pelo preditor. Essa correspondência depende de como a justificativa é construída e avaliada.

Uma explicação *contrafactual* pergunta o que precisaria mudar para que o modelo produzisse outra saída. No exemplo de classificação de aves, ela pode mencionar um atributo ausente que favoreceria uma classe alternativa. Em vídeo, pode associar um atributo de ação a uma região no espaço e no tempo. É necessário indicar o que pode ser modificado, quais mudanças são admitidas e como verificar se a entrada resultante continua fazendo sentido.

Métodos *interativos* permitem que o usuário peça detalhes, conteste uma resposta ou forneça retorno sobre a explicação. Métodos baseados em *fusão* examinam como as modalidades são combinadas, incluindo pesos e relações entre representações. Já métodos baseados em *atenção* visualizam ou analisam a seleção de informações durante o processamento. Essas famílias podem coexistir, na qual um sistema pode usar um grafo, atenção e interação com o usuário no mesmo procedimento (Rodis et al. 2024, seção IV-E).

6 Métricas de Explicabilidade

6.1 O que está sendo medido

A avaliação precisa começar pela propriedade que se deseja verificar. *Acurácia* da tarefa mede se a resposta está correta. *Compreensibilidade* examina se uma pessoa consegue entender a explicação. *Correspondência* com uma anotação humana mede concordância com uma referência. *Fidelidade*

diz respeito à ligação entre a explicação e o comportamento do preditor. Uma dessas propriedades não substitui automaticamente as demais.

O artigo distingue avaliações realizadas com especialistas em uma aplicação, avaliações com pessoas sem exigir especialização no domínio e avaliações baseadas em critérios formais. Essas três possibilidades correspondem, respectivamente, aos termos *application-grounded*, *human-grounded* e *functionally-grounded* (Rodis et al. 2024, seção V).

Considere duas justificativas para uma mesma resposta. A primeira pode ser mais curta e fácil de entender, a segunda pode mencionar características que efetivamente alteram a predição, mas usar uma linguagem menos acessível. Um estudo com usuários e um teste de perturbação podem avaliar aspectos diferentes dessas justificativas. O protocolo deve declarar qual aspecto cada resultado sustenta.

6.2 Métricas no domínio textual

Quando existem justificativas de referência, métodos de avaliação de linguagem podem comparar o texto gerado com essas anotações. A revisão reúne métricas com diferentes formas de comparação (Rodis et al. 2024, seção V-A):

- **BLEU:** utiliza correspondências de sequências contíguas de palavras, chamadas de n -gramas. Um bigrama contém duas palavras consecutivas. Portanto, a ordem dentro de cada sequência participa da comparação.
- **ROUGE-L:** considera a maior subsequência comum entre os textos, preservando a ordem dos elementos mesmo quando eles não são contíguos.
- **METEOR:** utiliza alinhamento entre palavras do texto gerado e das referências.
- **CIDEr:** examina a concordância com um conjunto de referências por meio de representações baseadas em n -gramas.
- **SPICE:** compara estruturas semânticas que representam objetos, atributos e relações, em vez de depender apenas da coincidência literal de palavras.
- **Similaridade de cosseno:** compara representações vetoriais das frases; o resultado depende também do modelo usado para produzir essas representações.

Como exemplo, “a ave apresenta peito amarelo” e “o peito da ave é amarelo” comunicam uma propriedade semelhante, mas diferem em algumas sequências de palavras. Por outro lado, uma frase idêntica à referência humana pode ser produzida por um explicador que não consultou a evidência usada pelo classificador.

6.3 Métricas no domínio visual

Para explicações visuais, uma possibilidade é comparar a região destacada com uma máscara ou caixa anotada. A interseção sobre união, ou IoU, mede a sobreposição entre dois conjuntos de pixels:

$$\text{IoU}(A, B) = \frac{|A \cap B|}{|A \cup B|}, \quad (4)$$

para uma união não vazia, em que A representa a região da explicação e B representa a região de referência. Em um exemplo hipotético, se a interseção ocupa 30 pixels e a união ocupa 50, a IoU é 0,6. Quando a explicação é um mapa contínuo, a transformação desse mapa em uma região também precisa ser definida.

Outras medidas discutidas no artigo avaliam a posição do máximo de atenção, a proporção de ativações dentro de uma região anotada, a ordenação dos pixels por relevância ou a distância entre distribuições de atenção. A *Earth Mover’s Distance* (EMD), por exemplo, compara distribuições

considerando o deslocamento necessário para transformar uma na outra (Rodis et al. 2024, seção V-B).

A concordância espacial com a anotação humana é informativa sobre localização. Para investigar o comportamento do preditor, a revisão também reúne testes de remoção e inserção. Na remoção, regiões consideradas importantes são retiradas progressivamente da entrada. Na inserção, elas são acrescentadas progressivamente a uma entrada de referência. Observa-se como varia a pontuação da saída analisada.

Uma forma de representar uma dessas comparações é

$$\Delta_R = s_c(x) - s_c(x^{(R \leftarrow b)}), \quad (5)$$

em que $s_c(x)$ é a pontuação atribuída à classe c na entrada original e $x^{(R \leftarrow b)}$ representa a entrada após substituir o conteúdo da região R pelo valor ou conteúdo de referência b , mantendo o restante da entrada inalterado. Um valor positivo indica queda dessa pontuação após a intervenção. Em um modelo multimodal, é preciso informar quais modalidades foram modificadas e quais permaneceram fixas.

A substituição pode envolver uma cor constante, ruído ou outra estratégia, e essas escolhas não são equivalentes. Uma entrada perturbada pode ficar fora das condições às quais o modelo foi exposto. Por isso, a análise deve relatar a operação realizada e comparar seus efeitos com controles, como regiões aleatórias de tamanho semelhante.

6.4 Avaliação das relações entre modalidades

Uma avaliação multimodal precisa examinar também as relações entre os componentes da explicação. Suponha que o texto diga “o objeto vermelho está à esquerda”, mas o mapa destaque um objeto azul à direita. A frase pode ser bem formada e o mapa pode coincidir com um objeto real; ainda assim, eles não se referem à mesma evidência.

A revisão descreve três abordagens voltadas a essa relação (Rodis et al. 2024, seção V-C):

- **Acurácia de conceito:** verifica a compatibilidade entre atributos textuais e regiões visuais em explicações contrafactuais de vídeo, utilizando relações entre atributos e caixas delimitadoras.
- **Complementaridade:** examina a informação oferecida pela combinação de componentes visuais e textuais. No método descrito, um módulo de raciocínio recebe os pares de explicações e fornece escores associados à classe prevista.
- **Fidelidade:** no protocolo específico apresentado, compara as predições do modelo original com as de um módulo que recebe as explicações, considerando acurácia e consistência entre respostas.

Um protocolo de leitura dos resultados pode reunir três perguntas: a explicação se refere à evidência presente? A predição responde de forma compatível quando essa evidência é alterada? As partes visual e textual da explicação se referem à mesma informação ou a informações que se complementam? Cada pergunta pede observações e controles próprios.

7 Desafios e limites discutidos no artigo

7.1 Atenção, fidelidade e causalidade

A revisão destaca a controvérsia sobre o uso de atenção como explicação. Pesos de atenção mostram como determinadas representações são ponderadas em uma operação, mas a predição depende também dessas representações e das etapas seguintes da rede. Os autores relatam estudos com discordâncias entre atenção e relevância estimada por gradientes, além de trabalhos que defendem uma análise condicionada à definição de explicação e à tarefa (Rodis et al. 2024, seção VI-B).

Uma leitura prática dessa discussão é identificar o que o mapa pretende demonstrar. Se ele descreve a distribuição dos pesos de atenção, a interpretação pode se limitar a esse componente. Se pretende demonstrar que certas regiões determinaram a resposta, essa afirmação requer evidências sobre o comportamento do preditor, como intervenções ou comparações controladas.

A causalidade aparece como outra direção de pesquisa. Saber que uma característica está associada a uma predição difere de compreender como mudanças nessa característica afetam a resposta.

7.2 Dados, generalização e definições

Os autores apontam falta de consenso na terminologia e na definição do que constitui uma boa explicação. Isso dificulta comparar trabalhos que usam o mesmo termo para objetivos diferentes. Antes de comparar *scores*, é necessário identificar se os métodos procuram localizar evidências, produzir justificativas para pessoas, reproduzir o comportamento do preditor ou descrever relações causais (Rodis et al. 2024, seção VI).

Outro limite é a dependência de tarefas e arquiteturas específicas. Um método desenvolvido para VQA pode depender da estrutura de pergunta e resposta e de anotações que não existem em uma tarefa com sensores. A aplicação em outro domínio exige verificar quais componentes, dados e critérios de avaliação permanecem disponíveis.

A revisão também discute vieses das justificativas humanas e escassez de explicações visuais anotadas. Pessoas podem oferecer razões diferentes para a mesma resposta, dependendo do conhecimento e do contexto de observação. Tratar uma única justificativa como a única explicação válida pode ocultar essa variação. Por outro lado, aceitar qualquer justificativa plausível impede avaliar sua relação com o preditor.

Ampliar o número de modalidades de explicação é apresentado como uma direção de pesquisa. Essa ampliação pode permitir mostrar outros aspectos da evidência, mas sua utilidade precisa ser examinada em relação ao usuário e à tarefa. Mais componentes também exigem verificar alinhamento, redundância, possíveis contradições e esforço de leitura.

Referências

Rodis, Nikolaos, Christos Sardianos, Panagiotis Radoglou-Grammatikis, Panagiotis Sarigiannidis, Iraklis Varlamis e Georgios Th. Papadopoulos (2024). “Multimodal Explainable Artificial Intelligence: A Comprehensive Review of Methodological Advances and Future Research Directions”. Em: *IEEE Access* 12, pp. 159794–159820. DOI: 10.1109/ACCESS.2024.3467062.